Università Politecnica delle Marche

Corso di Laurea Magistrale in Ingegneria Informatica e dell'Automazione



Prompt engineering per l'ottimizzazione del contesto nei modelli multimodali: Un Confronto tra CLIP e CLIP+CoOp

Relazione per l'esame di Computer Vision & Deep Learning

Ricci Ettore
Sebastianelli Nicola

Tutor: Alessandro Cacciatore
Anno accademico: 2024–2025

Indice

1 Introduzione **3**

2 Stato dell'arte **4**

2.1 CLIP: Contrastive Language–Image Pretraining 4

2.2 Zero-shot e Few-shot Learning 4

2.3 Prompt manuali e loro limiti 5

2.4 Prompt learning e il modello CoOp 5

3 Materiali e Metodi **7**

3.1 Obiettivi 7

3.2 Similarità coseno 7

3.3 Codice e configurazioni 8

3.4 Considerazioni aggiuntive 11

4 Risultati **12**

5 Conclusioni **16**

6 Sviluppi futuri **16**

Sommario

I modelli di apprendimento multimodale hanno rivoluzionato il modo in cui testo e immagini possono essere elaborati congiuntamente. *CLIP* (Contrastive Language–Image Pre-training), in particolare, apprende un unico spazio semantico condiviso ed abilita la classificazione *zero-shot*. Tuttavia, l'efficacia di CLIP dipende dalla qualità del *prompt* testuale usato in inferenza. *CoOp* (Context Optimization) affronta questo limite sostituendo i prompt manuali con token vettoriali addestrabili, ottimizzati senza modificare i pesi di CLIP. Questa tesina descrive il protocollo sperimentale adottato per confrontare CLIP e CLIP + CoOp su un insieme di dataset di dominio pubblico, analizzando in particolare l'impatto dell'ottimizzazione dei prompt sulla *coseno similarità* tra rappresentazioni visive e testuali e, di conseguenza, sulle performance di classificazione.

1 Introduzione

Negli ultimi anni, la diffusione di modelli pre-addestrati su larga scala ha reso possibile un nuovo approccio ai compiti di classificazione visiva, in particolare quelli caratterizzati da scarse risorse di addestramento. Tra questi, CLIP rappresenta una delle soluzioni più innovative, sfruttando una rete neurale addestrata su milioni di coppie immagine-testo per apprendere una rappresentazione multimodale condivisa. Rispetto all'approccio tradizionale all'apprendimento dei classificatori, in cui i concetti visivi a insieme chiuso vengono appresi da vettori casuali, il pre-addestramento visione-lingua consente di esplorare concetti visivi a insieme aperto attraverso un codificatore di testo ad alta capacità, portando a uno spazio semantico più ampio e, di conseguenza, rendendo le rappresentazioni apprese più trasferibili a compiti successivi.

Il vantaggio principale di CLIP consiste nella possibilità di generalizzare a nuovi compiti senza la necessità di fine-tuning. In uno scenario zero-shot, per eseguire la classificazione è sufficiente fornire al modello una serie di frasi descrittive che rappresentano le classi di interesse. Il modello confronta poi la rappresentazione di ciascuna immagine con quella dei prompt testuali e seleziona la classe più simile.

Tuttavia, questa strategia introduce una nuova sfida: la costruzione dei prompt. La qualità del linguaggio utilizzato nei prompt incide direttamente sulla capacità del modello di riconoscere le classi corrette. Prompt troppo generici o poco rappresentativi possono compromettere la performance, soprattutto in domini specializzati o con classi ambigue.

Per risolvere questa limitazione è stato proposto CoOp, un metodo di prompt learning che rinuncia al linguaggio naturale e sostituisce le parole con vettori addestrabili, ottimizzati direttamente sulla base di un dataset di supporto. L'idea è che la struttura del prompt possa essere appresa come parte del processo di apprendimento, senza intervento manuale.

Questa tesina esplora e confronta le due strategie, valutando l'impatto dell'ottimizzazione dei prompt sulle prestazioni generali del modello, mantenendo inalterati i pesi della rete CLIP.

2 Stato dell'arte

2.1 CLIP: Contrastive Language–Image Pretraining

CLIP [1] è un modello multimodale basato sull'apprendimento contrastivo. Come si vede in *Figura 1* è costituito da due componenti principali: un encoder per le immagini (basato su ResNet o Vision Transformer) e un encoder testuale (basato su Transformer). L'addestramento si basa su una *contrastive loss*, che incoraggia il modello ad allineare nel medesimo spazio vettoriale le rappresentazioni di immagini e dei testi corrispondenti, e a separare quelle non corrispondenti.

A differenza dei modelli tradizionali, CLIP non viene ottimizzato per un compito specifico, bensì apprende una rappresentazione generalizzata grazie a un'enorme quantità di dati (oltre 400 milioni di coppie immagine-testo). Questo consente al modello di eseguire classificazione zero-shot, in cui le classi vengono rappresentate tramite frasi in linguaggio naturale, senza alcuna fase di fine-tuning.

Esempio di prompt classico:

"una foto di un cane"
"una foto di un gatto"

Queste frasi vengono trasformate in vettori nello spazio testuale ed elaborate insieme all'immagine da classificare. La classe con embedding più simile all'immagine, in termini di cosine similarity, viene selezionata come output.

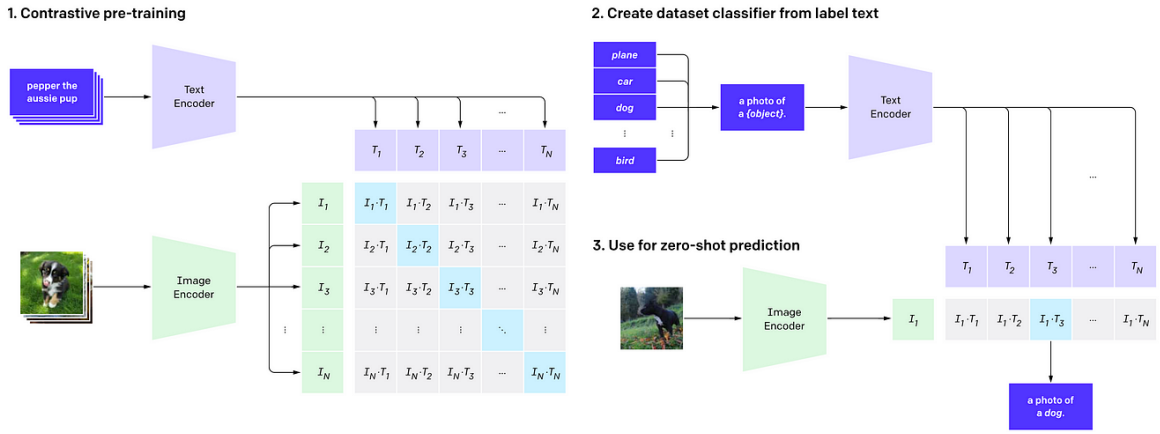


Figura 1: Schema semplificato dell'architettura CLIP.

2.2 Zero-shot e Few-shot Learning

Lo *zero-shot learning* (ZSL) è un paradigma di apprendimento in cui un modello deve riconoscere classi mai viste durante l'addestramento, sfruttando descrizioni semantiche ausiliarie [3]. Nel *few-shot learning* (FSL), al modello sono forniti pochissimi esempi etichettati per ogni nuova classe, con l'obiettivo di adattarsi rapidamente a partire da poche osservazioni [4].

CLIP [1] ha rappresentato un punto di svolta per lo ZSL, grazie al suo spazio multimodale condiviso che consente di misurare direttamente la similarità coseno tra immagini e descrizioni testuali. Tuttavia, le prestazioni dipendono fortemente dalla formulazione del prompt.

Per ovviare a questo limite, **CoOp** [2] sostituisce il prompt testuale statico con token vettoriali addestrabili, ottimizzati via backpropagation mantenendo congelati i pesi di CLIP. Ciò rende CoOp adatto anche a scenari few-shot, dove pochi esempi supervisionati vengono impiegati per ottimizzare i token.

L'interesse verso il prompt learning ha portato a ulteriori estensioni, come **CoCoOp** [5], che condiziona dinamicamente il prompt sull'immagine di input.

2.3 Prompt manuali e loro limiti

I prompt manuali rappresentano il principale mezzo con cui CLIP esprime le classi target in modalità *zero-shot*. Tuttavia, questa strategia presenta importanti limiti:

- Non sempre i prompt riflettono correttamente le caratteristiche visive della classe.
- Richiedono una buona comprensione semantica del dominio.
- Possono essere subottimali in presenza di classi ambigue o con significati multipli.
- L'efficacia del prompt può variare significativamente a seconda del dataset.

2.4 Prompt learning e il modello CoOp

Il *prompt learning* è una nuova frontiera nell'uso di modelli pre-addestrati: invece di aggiornare i pesi del modello, si apprendono solo le rappresentazioni di input, ovvero i prompt stessi. CoOp [2] è un esempio emblematico di questa filosofia, in cui i prompt non sono più frasi testuali, ma sequenze di token vettoriali addestrabili (*Figura 2*).

Esistono due implementazioni di CoOp, basate sul contesto, in questo ambito con contesto si intende la sequenza di token vettoriali addestrabili che precede (o in alcuni casi circonda) il nome della classe nel prompt fornito al text encoder di CLIP. La prima implementazione si basa sul contesto unificato, che condivide lo stesso contesto con tutte le classi e funziona bene nella maggior parte delle categorie, mentre l'altra si basa su un contesto specifico per classe, che impara un insieme specifico di token di contesto per ogni classe ed è considerata più adatta per alcune categorie.

1. **Contesto unificato:** il prompt dato all'encoder testuale è progettato come

$$[v_1, v_2, \ldots, v_M, \text{classe}]$$

   dove v_1 a v_M sono token di contesto che il modello apprende automaticamente tramite backpropagation. Gli encoder di CLIP rimangono congelati, rendendo il metodo efficiente e meno costoso del fine-tuning. C'è anche la possibilità di inserire il token

di classe a metà del vettore dei token di contesto per aumentare la flessbilità per l'apprendimento dei prompt.

2. **Contesto specifico:** i vettori di contesto sono indipendenti per ogni classe, particolarmente utile per alcuni compiti di classificazione

Per questo progetto sono stati realizzati esperimenti utilizzando esclusivamente il contesto unificato

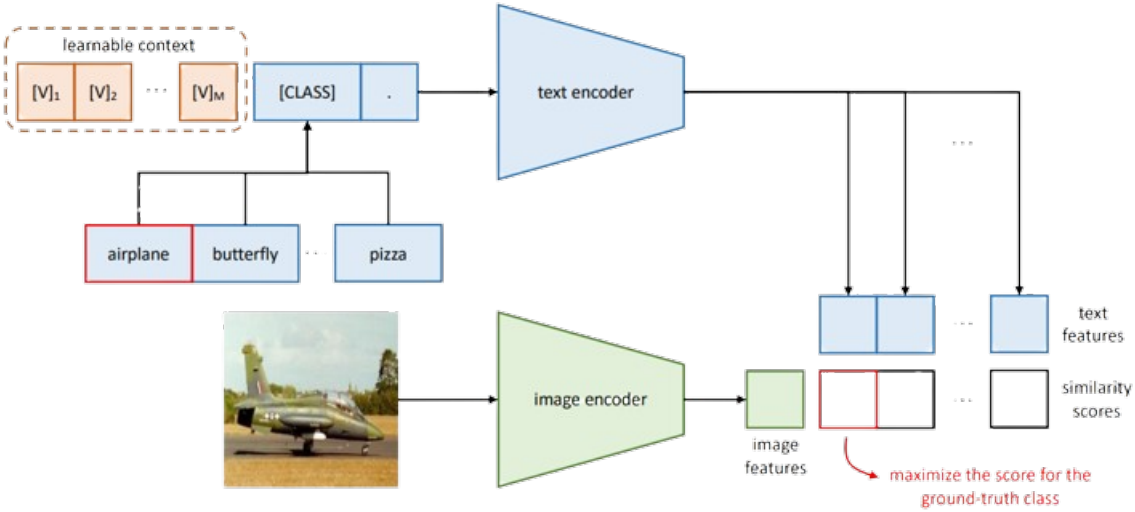


Figura 2: Architettura di CoOp: i token di contesto addestrabili precedono il nome della classe.

3 Materiali e Metodi

3.1 Obiettivi

L'obiettivo principale di questo studio è confrontare empiricamente due diverse strategie di classificazione basate sul modello CLIP (Contrastive Language–Image Pretraining):

1. **CLIP in modalità zero-shot**, che utilizza prompt manuali statici formulati in linguaggio naturale del tipo: *"una foto di un {classe}"*.
2. **CLIP + CoOp (Context Optimization)**, che sostituisce i prompt testuali con una sequenza di $M = 16$ token vettoriali appresi automaticamente durante il training. Questi token precedono il nome della classe nel prompt e vengono ottimizzati via backpropagation, mentre i pesi del modello CLIP restano congelati, conformemente alla implementazione ufficiale[1].

L'esperimento si propone di rispondere alle seguenti domande di ricerca:

- In che misura i prompt ottimizzati migliorano la **performance di classificazione** rispetto ai prompt statici?
- I prompt appresi riescono a **massimizzare la similarità semantica** tra immagini e descrizioni testuali, misurata tramite similarità coseno?

Le metriche di valutazione utilizzate sono:

- **Accuratezza**: percentuale di predizioni corrette;
- **Similarità coseno media** tra l'embedding dell'immagine e quello del prompt corretto;

3.2 Similarità coseno

La **coseno similarità** è una misura matematica utilizzata per valutare la somiglianza tra due vettori in uno spazio multidimensionale, ed è molto comune nel campo del *Natural Language Processing* (NLP) e del recupero dell'informazione. Essa si basa sul calcolo del *coseno dell'angolo* tra due vettori, producendo un valore compreso tra -1 e 1: un valore vicino a 1 indica una forte similarità direzionale, ovvero concettuale, indipendentemente dalla loro magnitudine.

Formalmente:

$$\text{sim}(x, y) = \frac{x \cdot y}{\|x\|\|y\|}$$

Nel nostro contesto:

- $x = f_{\text{img}}(I)$: rappresentazione visiva;

[1] Repository: `https://github.com/KaiyangZhou/CoOp`

- $y = f_{\text{text}}(P_c)$: rappresentazione testuale del prompt della classe c.

Il logit di output per ciascuna classe è proporzionale alla similarità coseno tra questi due vettori. Secondo la nostra ipotesi l'ottimizzazione dei prompt in CoOp potrebbe massimizzare questa misura, migliorando così l'allineamento semantico. Misurare la similarità dopo il training di CoOp permette di valutare quanto i prompt ottimizzati riescano ad *avvicinare semanticamente* immagine e descrizione.

3.3 Codice e configurazioni

Toolkit e ambiente Gli esperimenti sono stati condotti utilizzando la codebase ufficiale di `CoOp`, disponibile su GitHub[2], sviluppata dagli autori dell'articolo di riferimento. La base software è costruita su `Dassl.pytorch`, un framework modulare per domain adaptation, e utilizza `PyTorch` (versione $>$ 1.10). L'ambiente di sviluppo include:

- Sistema operativo: Ubuntu 20.04
- GPU: 4 x NVIDIA Ampere A100 GPUs, 64GB
- Python: versione 3.9

Questa configurazione garantisce piena compatibilità con i modelli preaddestrati CLIP, e consente un training efficiente dei prompt CoOp anche su dataset di medie dimensioni.

Dataset Sono stati selezionati due dataset, entrambi forniti con script di caricamento e split standard nella repository ufficiale:

- **Caltech-101**: dataset ampiamente utilizzato in visione artificiale, composto da 101 classi bilanciate tra animali, oggetti e soggetti artificiali. È utile per valutare la capacità di generalizzazione su concetti visivi comuni.

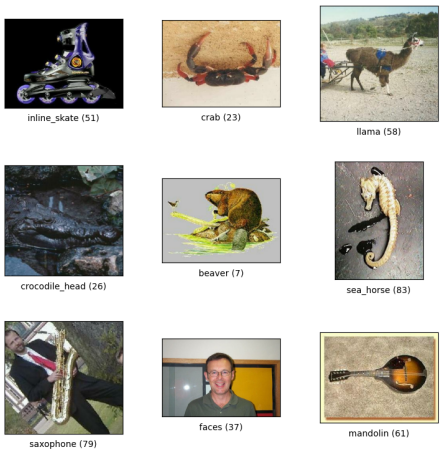


Figura 3: Esempi di immagini presenti all'interno del dataset Caltech101

[2] `https://github.com/KaiyangZhou/CoOp`

- **EuroSAT**: dataset di immagini satellitari RGB appartenenti a 10 classi di copertura del suolo. È utilizzato per testare la robustezza semantica del modello in uno scenario *out-of-distribution*, in quanto il dominio (telerilevamento) è molto distante da quello dei dati su cui CLIP è stato preaddestrato (immagini web).



Figura 4: Esempi di immagini presenti all'interno del dataset EuroSAT

La scelta di questi due dataset consente di testare sia la capacità del modello di mantenere alte prestazioni in domini noti, sia la sua resilienza semantica in contesti nuovi.

Prompt e inizializzazione Nel caso del modello **CLIP** (zero-shot), per ogni classe viene generato un prompt testuale fisso della forma *"una foto di un {classe}"*. Questa forma segue lo standard proposto da Radford et al. (2021), e riflette il pre-training originale di CLIP su immagini associate a descrizioni brevi.

Per **CoOp**, il prompt è parametrizzato come una sequenza di vettori:

$$[v_1, v_2, \ldots, v_M, \text{classe}]$$

dove $M = 16$ è il numero di token di contesto appresi. Ogni token $v_i \in \mathbb{R}^{512}$ viene inizializzato con l'embedding della frase "a photo of a", garantendo una coerenza semantica iniziale con i prompt zero-shot. Questa inizializzazione aiuta a stabilizzare l'apprendimento nelle prime epoche e ad evitare divergenze, come confermato da esperimenti nel paper di riferimento.

Durante il training, solo questi token vettoriali sono soggetti ad aggiornamento; gli encoder visivo e testuale di CLIP restano completamente **congelati**, al fine di preservare le rappresentazioni acquisite durante il pre-training su larga scala.

Configurazioni di training Le configurazioni sperimentali sono definite nel file `rn50_ep50.yaml`, che contiene i seguenti iperparametri:

- **Backbone**: ResNet-50, scelto per la sua efficienza computazionale e l'ampio supporto nella letteratura.

- **Batch size**: 32, valore bilanciato per stabilità e velocità di training su GPU.
- **Ottimizzatore**: Stochastic Gradient Descent (SGD), con learning rate iniziale $\eta = 0.002$.
- **Scheduler**: *cosine decay*, che decresce il learning rate in modo graduale, migliorando la convergenza nelle ultime epoche.
- **Numero di epoche**: 50, sufficiente per dataset mediamente piccoli come Caltech-101 e EuroSAT.

La fase di training include anche un **warm-up iniziale**, in cui il learning rate è mantenuto basso (10^{-5}) nella prima epoca per evitare gradienti esplosivi, come suggerito dagli autori originali.

Esecuzione degli esperimenti Gli esperimenti sono stati eseguiti sui server HPC messi a disposizione da **CINECA**, uno dei principali centri di supercalcolo a livello europeo. L'accesso ai nodi di calcolo è avvenuto tramite protocollo `SSH` da terminale, utilizzando autenticazione a chiave pubblica/privata.

Il sistema di gestione dei job utilizzato è **SLURM** (Simple Linux Utility for Resource Management), uno scheduler ampiamente adottato nei sistemi di calcolo ad alte prestazioni. I job di addestramento sono stati sottomessi con il comando `sbatch`, utilizzando script `.sh` contenenti le direttive `#SBATCH` necessarie per specificare le risorse (es. numero di GPU, tempo limite, memoria richiesta, partizione di esecuzione).

Un esempio semplificato di sottomissione è:

```
sbatch run_train_clipcoop.sh
```

All'interno dello script SLURM si specificano le risorse necessarie (GPU, memoria, tempo di esecuzione) e i parametri di input per lo script di training Python.

Script e parametri configurabili L'interazione con la codebase di CoOp avviene principalmente attraverso gli script contenuti nella cartella `scripts/coop/`, tra cui:

- `main.sh` — per il training few-shot supervisionato (CoOp).
- `zeroshot.sh` — per l'inferenza con CLIP zero-shot.

Gli script accettano numerosi parametri personalizzabili da riga di comando:

- `DATASET`: nome del dataset su cui effettuare il training (`caltech101`, `eurosat`, ecc.);
- `CFG`: nome del file YAML contenente la configurazione del modello (es. `rn50_ep50.yaml`);
- `N_CTX`: numero di token di contesto ottimizzati (tipicamente 16);

- `CTX_POS`: posizione del nome della classe nel prompt (ad es. `end` o `middle`);
- `CSC`: flag che abilita o disabilita l'uso di *class-specific context* (True/False);
- `SHOTS`: numero di esempi per classe nel setting few-shot (es. 1, 4, 16).

Questa struttura modulare consente di lanciare esperimenti multipli con differenti combinazioni di parametri, sfruttando la parallelizzazione nativa del cluster e facilitando l'esplorazione sistematica dello spazio degli iperparametri.

3.4 Considerazioni aggiuntive

Per semplicità, tutti gli esperimenti sono stati condotti con contesto unificato (no CSC). I prompt sono stati mantenuti coerenti su entrambi i dataset. EuroSAT è stato scelto come test per la robustezza in scenari out-of-domain, data la sua distanza semantica dai dati di pre-training.

4 Risultati

I risultati sperimentali sono stati raccolti confrontando le performance di CLIP in modalità *zero-shot* con quelle ottenute mediante l'utilizzo di *CoOp* in regime *few-shot*. Gli esperimenti sono stati replicati su due dataset di riferimento: **Caltech101**, che presenta un'elevata varietà semantica, e **EuroSAT**, che contiene immagini satellitari suddivise in categorie geografiche.

Per ogni dataset sono stati misurati:

- l'accuratezza al variare del numero di *shot* (esempi supervisionati per classe);
- la media della *cosine similarity* tra rappresentazioni di immagini e prompt corrispondenti.

I grafici seguenti(*Figura 5, Figura 6)* riportano, per ciascun dataset, l'andamento delle due metriche in funzione del numero di *shot* ($k = 1, 4, 8, 16$), confrontando CLIP in modalità zero-shot (prompt statico) con CLIP + CoOp (prompt ottimizzato), per quanto riguarda CLIP + CoOp sono stati effettuati dei testi sia con il token *class* a metà del prompt che alla fine.

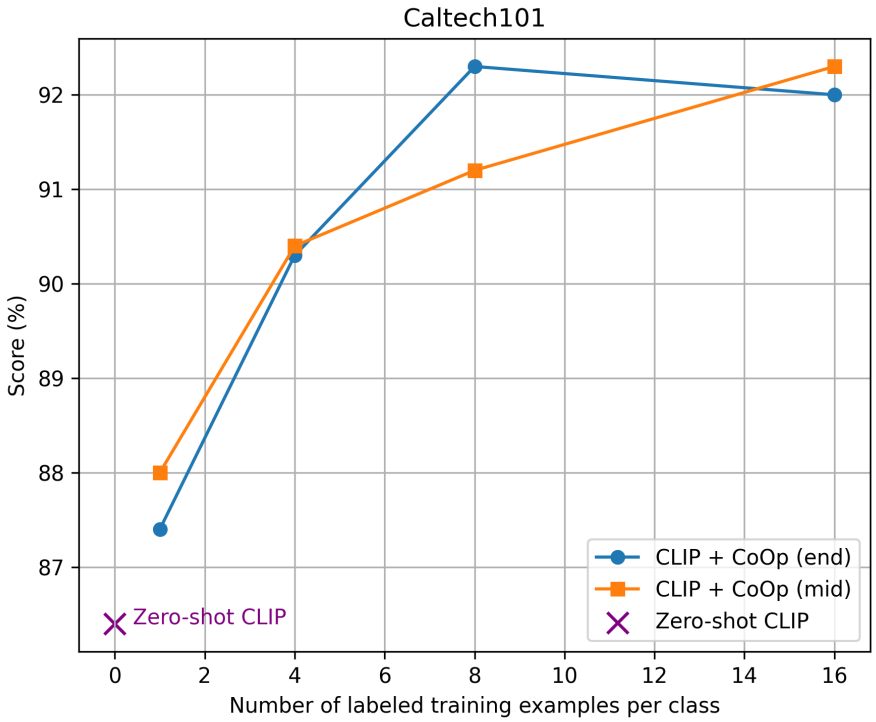


Figura 5: Accuratezza e similarità coseno su Caltech101 al variare degli shot.

Metodo	1-shot	4-shot	8-shot	16-shot
CLIP + CoOp (mid)	88.0%	90.4%	91.2%	92.3%
CLIP + CoOp (end)	87.2%	90.3%	92.3%	92.0%
CLIP Zero-Shot	Accuracy: 86.4%			

Tabella 1: Confronto dell'accuracy sul dataset Caltech101 tra CLIP Zero-Shot e CLIP + CoOp con diverse quantità di shot e posizione della classe ('mid', 'end').

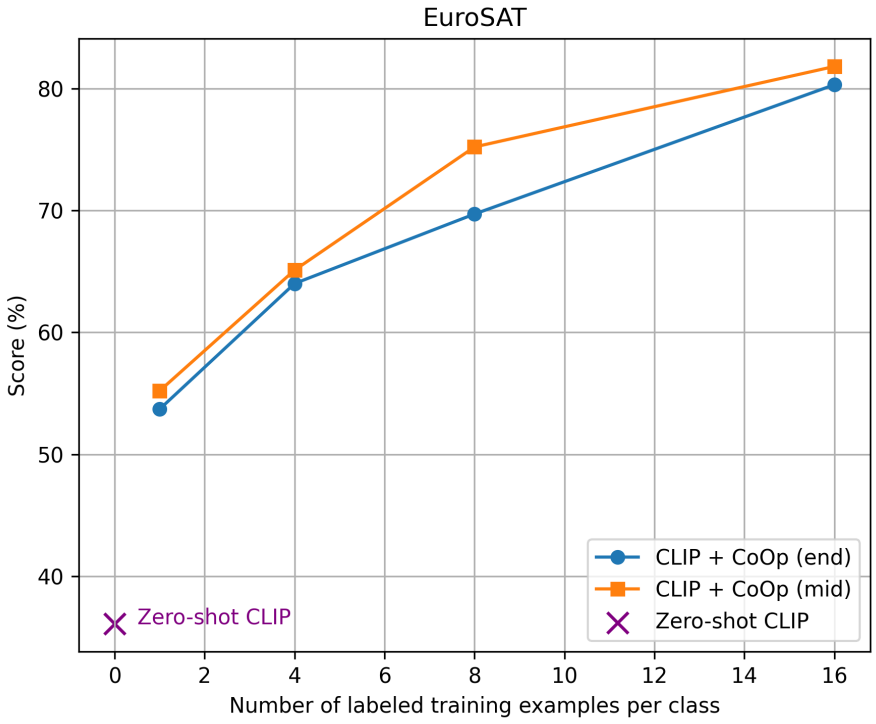


Figura 6: Accuratezza e similarità coseno su EuroSAT al variare degli shot.

Metodo	1-shot	4-shot	8-shot	16-shot
CLIP + CoOp (mid)	55.2%	65.1%	75.2%	81.8%
CLIP + CoOp (end)	53.7%	64.0%	69.6%	80.3%
CLIP Zero-Shot	Accuracy: 36.1%			

Tabella 2: Confronto dell'accuracy sul dataset EuroSAT tra CLIP Zero-Shot e CLIP + CoOp con diverse quantità di shot e posizione della classe ('mid', 'end').

L'analisi dei risultati mostra un trend coerente tra i due dataset:

- In modalità **zero-shot**, CLIP ottiene risultati competitivi.
- L'introduzione di CoOp migliora sensibilmente la performance al crescere del numero di *shot*, con guadagni particolarmente evidenti già a partire da 4–8 esempi per classe.

In generale, i risultati confermano l'efficacia del prompt learning come strategia alternativa al fine-tuning completo, capace di adattare CLIP a domini specifici con un costo computazionale contenuto.

Per rendere più intuitivo il guadagno ottenuto tramite prompt ottimizzati, in Figura 7 viene mostrato l'incremento percentuale di accuratezza tra CLIP (zero-shot) e CoOp (few-shot, $k = 1, 4, 8, 16$) su entrambi i dataset.

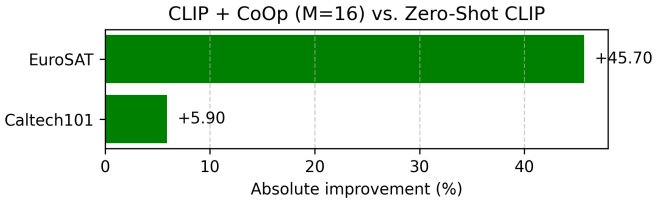


Figura 7: Incremento percentuale di accuratezza con CoOp rispetto a CLIP zero-shot.

Come si osserva, l'incremento è marcato in entrambi i casi, con un vantaggio più netto su EuroSAT. Caltech101 mostra anch'esso un miglioramento significativo, pur partendo da una baseline più elevata.

Oltre all'accuratezza, è stata analizzata la **coseno similarità** media tra embedding visivo e testuale associati alla classe corretta. Nelle tabelle Tabella 3 e Tabella 4 sono rappresentate le distribuzione delle similarità ottenute con CLIP e CoOp, aggregata su tutti i campioni test dei due dataset. L'analisi è stata condotta considerando la configurazione in cui il nome della classe è posizionato alla fine del prompt (end).

Tabella 3: Confronto tra CLIP e CoOp sul dataset **Caltech101**.

Shot	**CoOp > CLIP**	**CLIP > CoOp**	**Uguali**
1	2.01%	97.98%	0.01%
4	2.80%	97.20%	0.00%
8	1.65%	98.34%	0.01%
16	0.8%	99.1%	0.1%

Tabella 4: Confronto tra CLIP e CoOp sul dataset **EuroSAT**.

Shot	**CoOp > CLIP**	**CLIP > CoOp**	**Uguali**
1	0.13%	99.87%	0.00%
4	0.42%	99.57%	0.01%
8	0.38%	99.6%	0.02%
16	2.40%	97.56%	0.04%

Contrariamente all'ipotesi iniziale, CLIP con prompt manuali ha prodotto valori medi di coseno similarità superiori rispetto a CLIP + CoOp. Questo fenomeno è stato riscontrato sistematicamente su entrambi i dataset.

L'interpretazione di questo risultato trova conferma nella letteratura recente. In particolare, nell'articolo *Understanding and Mitigating Miscalibration in Prompt Tuning for Vision-Language Models* [7] viene mostrato che CoOp, essendo ottimizzato con una loss di tipo cross-entropia, non promuove una separazione efficace tra classi, al contrario della loss contrastiva usata in CLIP. Mentre la loss contrastiva incoraggia l'allineamento selettivo fra coppie corrette e la separazione da quelle sbagliate, la cross-entropia si concentra esclusivamente sull'output corretto, trascurando i margini di separabilità tra classi.

In pratica, CoOp sembra ottimizzare i prompt in modo che il logit corretto sia più elevato, ma ciò non implica necessariamente un maggiore allineamento semantico in termini di similarità vettoriale.

Questa osservazione ha implicazioni importanti: sebbene CoOp possa migliorare l'accuratezza nominale, ciò avviene a discapito dell'interpretabilità geometrica nello spazio embedding condiviso. Il modello aumenta la propria confidenza nelle predizioni, ma ciò non implica una maggiore vicinanza semantica tra le rappresentazioni visive e testuali.

5 Conclusioni

In questo studio, abbiamo analizzato due diverse strategie per la classificazione basata su CLIP: il metodo tradizionale *zero-shot* con prompt manuali e il metodo *few-shot* basato su CoOp, che ottimizza i prompt mediante l'apprendimento di token vettoriali.

I risultati sperimentali hanno mostrato che:

- CoOp migliora l'accuratezza su entrambi i dataset considerati rispetto all'approccio zero-shot, soprattutto al crescere del numero di *shot* forniti durante l'addestramento.
- L'analisi della *cosine similarity* ha evidenziato un comportamento controintuitivo: CLIP mostra una similarità media più elevata tra rappresentazioni visive e testuali rispetto a CoOp. Questo fenomeno è stato spiegato in letteratura [7] in termini di miscalibrazione del modello.
- Come osservato da Wang et al., CoOp tende a generare rappresentazioni testuali meno coerenti su classi non viste, a causa dell'utilizzo di una funzione obiettivo basata su *cross-entropy* che, a differenza della *contrastive loss* di CLIP, non promuove un'allineamento robusto tra tutte le classi nello spazio semantico. Questo porta CoOp a essere eccessivamente sicuro nelle sue predizioni anche quando errate, specialmente su classi non presenti durante il training, generando un effetto noto come *overconfidence*.

Tali considerazioni suggeriscono che, sebbene il *prompt learning* mediante CoOp sia efficace nel migliorare le prestazioni numeriche in scenari *few-shot*, esso presenta limiti strutturali legati alla calibrazione delle predizioni. L'integrazione di tecniche di regolarizzazione, come proposto nell'approccio DOR [7], rappresenta una direzione promettente per bilanciare accuratezza e affidabilità del modello.

Implicazioni pratiche: CoOp resta un metodo vantaggioso per applicazioni con risorse etichettate limitate, grazie alla sua efficienza computazionale e facilità d'integrazione. Tuttavia, il comportamento del modello sulle classi non viste va interpretato con cautela, soprattutto in ambiti sensibili dove l'affidabilità delle probabilità predette è cruciale.

6 Sviluppi futuri

Questo lavoro apre a numerose prospettive di approfondimento, sia dal punto di vista sperimentale che metodologico.

- **Integrazione di tecniche di regolarizzazione:** i risultati sperimentali e le osservazioni tratte da [7] evidenziano una limitata capacità di generalizzazione del metodo CoOp su classi non viste, attribuita a un comportamento miscalibrato del modello. In futuro, si potrebbe esplorare l'impiego di tecniche di regolarizzazione come *Dynamic Outlier Regularization (DOR)*, per migliorare la calibrazione senza compromettere le performance.

- **Estensione a dataset più complessi:** l'analisi potrebbe essere replicata su dataset ad alta variabilità semantica (come ImageNet o DomainNet), o in contesti di dominio specializzato (ad esempio immagini satellitari avanzate o dati medici), per valutare la robustezza delle strategie di prompt tuning in scenari realistici.
- **Confronto con altri approcci di prompt learning:** si propone di estendere il confronto oltre CoOp, includendo metodi alternativi come ProDA [8], VPT [9] o Tip-Adapter [10]. Questo permetterebbe una valutazione più completa delle implicazioni semantiche e delle capacità di generalizzazione del prompt learning.
- **Applicazioni a compiti multimodali:** infine, si potrebbe valutare l'efficacia delle strategie di prompt tuning su altri task vision-language, come image retrieval, captioning o visual grounding, per verificare la trasferibilità dei benefici osservati oltre la classificazione.

Riferimenti bibliografici

[1] Radford, A., Kim, J.W., Hallacy, C., *et al.*, "Learning Transferable Visual Models From Natural Language Supervision," *arXiv:2103.00020*, 2021.

[2] K. Zhou, J. Yang, Chen Change Loy, Z. Liu *et al.*, "Learning to Prompt for Vision-Language Models," *IJCV*, 2022.

[3] Y. Xian, B. Schiele, and Z. Akata, "Zero-shot learning—A comprehensive evaluation of the good, the bad and the ugly," *IEEE TPAMI*, 2019.

[4] J. Snell, K. Swersky, and R. S. Zemel, "Prototypical networks for few-shot learning," in *NeurIPS*, 2017.

[5] K. Zhou, J. Yang, Chen Change Loy, Z. Liu, "Conditional Prompt Learning for Vision-Language Models," in *CVPR*, 2022.

[6] Qingci An, Yannis Kevrekidis, Fei Lu, Mauro Maggioni, "Prompt Distribution Learning," *arXiv:2207.05242*, 2022.

[7] Wang, Shuoyuan, Li, Yixuan, and Wei, Hongxin. *"Understanding and Mitigating Miscalibration in Prompt Tuning for Vision-Language Models"*. arXiv:2410.02681, 2024.

[8] Lu, C., Zhang, X., Huang, Z., Van Gool, L., Guo, Y., Wang, Y., Li, Y., Wang, Y., & Lu, C. (2022). *Prompt Distribution Learning for Vision-Language Models.* In *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR).*

[9] Jia, X. L., Yang, M., Zhang, Z., Lim, S.-N., Bansal, M., & Hariharan, B. (2022). *Visual Prompt Tuning.* arXiv preprint arXiv:2203.12119.

[10] Zhang, X., Li, X., Zhang, Y., & Huang, Z. (2022). *Tip-Adapter: Training-free Adaptation of CLIP for Few-shot Classification.* arXiv preprint arXiv:2207.09519.